

LAB8-BD2

Villegas Suarez, Elmer Jose Manuel
Hernández Yataco, Josué Renzo
Cose Rojas, Joseph Anderson

May 2026

1 Pregunta 5

Dado que estamos trabajando con un volumen de datos relativamente pequeño (1,217 filas) el tiempo que tarda PostgreSQL en resolver una consulta es de apenas unos pocos milisegundos. Si medimos el tiempo de una sola ejecución, cualquier proceso en segundo plano de la computadora podría causar un 'pico' de lentitud falso y arruinar la gráfica.

Por lo tanto, para obtener datos precisos y estables, el código de prueba ejecuta toda la batería de 12 consultas 10 veces seguidas. Luego, se calcula el tiempo promedio. Esto elimina el 'ruido' de la computadora y nos da el tiempo real de procesamiento de la base de datos.

1.1 Graficas con y sin Indice:

En la siguiente gráfica, PostgreSQL está haciendo un *Sequential Scan*. Como no tiene un índice, lee uno por uno todos los registros de la tabla. A más noticias, más trabajo tiene que hacer, por lo que el tiempo de ejecución crece de forma proporcional a la cantidad de datos.




Figure 1: Gráfica sin Índice

Para la gráfica con índice, vamos a crear el siguiente índice en la base de datos:

```
CREATE INDEX idx_bag_of_words ON noticias USING GIN (bag_of_words);
```

Al hacer esto, el motor ya no realizará un *Sequential Scan*, sino un *Index Scan*.




Figure 2: Gráfica con Índice

1.2 Analisis:

El uso de un índice GIN es obligatorio cuando se trabaja con columnas JSONB en bases de datos relacionales, ya que convierte un problema de rendimiento que empeora con el tiempo (*Sequential Scan*) en búsquedas casi instantáneas (*Index Scan*).

El buscador solo fue preciso porque se aplicó la misma limpieza (*stemming* y minúsculas) tanto al guardar los datos como al momento de parsear la consulta del usuario, evitando desajustes de vocabulario.